

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет Информационных технологий и управления
Кафедра Интеллектуальных информационных технологий

ОТЧЁТ
по ознакомительной практике

Выполнил:

М. П. Климков

Студент группы
321701

Проверил:

Н. В. Малиновская

Минск 2024

СОДЕРЖАНИЕ

Введение	3
1 Постановка задачи	4
2 Формализованные фрагменты теории интеллектуальных компьютер- ных систем и технологий их разработки	5
2.1 Современное состояние работ в области разработки компьюте- ров для интеллектуальных систем	5
3 Формальная семантическая спецификация библиографических ис- точников	10
Заключение	12
Список использованных источников	13

ВВЕДЕНИЕ

Цель:

Закрепить практические навыки формализации информации в интеллектуальных системах с использованием семантических сетей.

Задачи:

- Построение формализованных фрагментов теории интеллектуальных компьютерных систем и технологий их разработки.
- Построение формальной семантической спецификации библиографических источников, соответствующих указанным выше фрагментам.
- Оформление конкретных предложений по развитию текущей версии Стандарта интеллектуальных компьютерных систем и технологий их разработки.

1 ПОСТАНОВКА ЗАДАЧИ

Часть 2 Учебной дисциплины "Представление и обработка информации в интеллектуальных системах"

⇒ библиографическая ссылка*:

- Стандарт OSTIS
- Материалы конференций OSTIS
- Журнал "Онтология проектирования"
- Справочник по Искусственному интеллекту в трех томах
- Энциклопедический словарь по информатике для начинающих
- Толковый словарь по Искусственному интеллекту

⇒ URL*:

[<http://raai.org/library/tolk/aivoc.html>]

- ...

⇒ аттестационные вопросы*:

- ⟨ • Вопрос 1 по Части 2 Учебной дисциплины "Представление и обработка информации в интеллектуальных системах"
- Вопрос 2 по Части 2 Учебной дисциплины "Представление и обработка информации в интеллектуальных системах"
- ...

⟩

Вопрос 1 по Части 2 Учебной дисциплины "Представление и обработка информации в интеллектуальных системах"

:= [Понятие кибернетической системы. Архитектура и типология кибернетических систем. Критерии качества (эффективности) кибернетических систем. Факторы интеллектуальности кибернетических систем.]

⇒ библиографическая ссылка*:

- Предметная область и онтология кибернетических систем
∈ раздел Стандарта OSTIS
- ЭнциклК-1974кн

:= [Энциклопедия кибернетики. В 2-х томах. – Киев, 1974.]

⇔ следует отличать*:

Вопрос 3 по Части 2 Учебной дисциплины "Представление и обработка информации в интеллектуальных системах"

2 ФОРМАЛИЗОВАННЫЕ ФРАГМЕНТЫ ТЕОРИИ ИНТЕЛЛЕКТУАЛЬНЫХ КОМПЬЮТЕРНЫХ СИСТЕМ И ТЕХНОЛОГИЙ ИХ РАЗРАБОТКИ

2.1 Современное состояние работ в области разработки компьютеров для интеллектуальных систем

машина фон-Неймана

- $\coloneqq$ [абстрактная машина фон-Неймана.]
- $\in$ *абстрактная машина обработки информации*
- $\Rightarrow$ *принципы в основе**:
- {• [Информация в памяти представляется в виде последовательности строк символов в бинарном алфавите ("0" или "1").]
 - [Память машины представляет собой последовательность адресуемых ячеек памяти.]
 - [В каждую ячейку может быть записана любая строка символов в бинарном алфавите. При этом длина строк для всех адресуемых ячеек одинакова (в текущем стандарте ячеек, называемых байтами, равна 8 бит).]
 - [Каждой ячейке памяти взаимно однозначно соответствует битовая строка, обозначающая эту ячейку и являющаяся ее адресом.]
 - [Каждому типу элементарных действий (операций), выполняемых в памяти машины фон-Неймана, взаимно однозначно ставится ее идентификатор, который в памяти представляется также в виде битовой строки.]
 - [Программа, выполняемая в памяти, хранится в памяти в виде последовательности спецификаций конкретных операций (команд).]
 - [Таким образом, и обрабатываемые данные, и программы для обработки этих данных хранятся в одной и той же памяти (в отличие, например, от Гарвардской архитектуры) и кодируются одинаковым образом.]
- }

Электронная вычислительная машина

- $\coloneqq$ [комплекс технических, аппаратных и программных средств, предназначенных для автоматической обработки информации, вычислений, автоматического управления.]
- $\Rightarrow$ *Виды**:
- {• Супер ЭВМ
 - Большие ЭВМ
 - Мини-ЭВМ
 - Микро-ЭВМ
- }
- $\Rightarrow$ *Компоненты**:
- {• Процессор
- $\Rightarrow$ *пояснение**:

[Центральный элемент ЭВМ, ответственный за выполнение всех вычислительных операций. Процессор обрабатывает данные, управля-

ет операциями чтения и записи, а также обеспечивает взаимодействие между различными компонентами машины.]

- *Память*
⇒ *пояснение**:
[Основной компонент для хранения информации на временной или постоянной основе. Виды памяти включают оперативную (RAM), кэш-память, а также постоянную память (например, жесткий диск).]
 - *Устройство ввода-вывода*
⇒ *пояснение**:
[Подсистема, отвечающая за взаимодействие ЭВМ с внешними устройствами – клавиатурой, мышью, монитором, принтером и другими периферийными устройствами.]
 - *Шина данных*
⇒ *пояснение**:
[Набор проводов или каналов, по которым передаются данные между различными компонентами ЭВМ. Шина данных играет ключевую роль в обмене информацией внутри системы.]
 - *Устройства хранения данных*
⇒ *пояснение**:
[Внешние устройства, предназначенные для долгосрочного хранения информации, такие как компакт-диски, флэш-накопители, облачное хранилище и другие.]
- }

Графический процессор

- := [GPU]
:= [процессор, предназначенный для ускорения рендеринга графики и параллельных вычислений.]
⇒ *Сферы применения**:
{
 - *Ускорение задач искусственного интеллекта*
 - *Глубокое обучение*
 - *Аналитика данных*
 - *Научная симуляция*}
- ⇒ *Архитектура**:
{
 - *Вычислительные блоки*
⇒ *пояснение**:
[Вычислительные блоки (CU) образуют основные вычислительные элементы в GPU. Каждый CU состоит из набора ядер, которые работают в унисон для одновременного выполнения задач. GPU может содержать от нескольких до нескольких тысяч CU.]- *Ядра*
⇒ *пояснение**:
[Отдельные вычислительные блоки в каждом CU.]
- *Иерархия памяти*
⇒ *пояснение**:
[Сложная иерархия памяти в GPU разработана, чтобы обеспечивать высокоскоростной доступа к данным. Она включает в себя глобаль-

ную, общую, локальную и частную память, каждая из которых имеет свои уникальные характеристики и возможности использования.]

- *Потоковые мультипроцессоры*

⇒ *пояснение**:

[В архитектуре NVIDIA GPU потоковый мультипроцессор (SM) служит основным вычислительным блоком, он управляет и выполняет потоки в группах. Каждый SM содержит несколько ядер CUDA, а несколько SM составляют GPU.]

- *Выходные блоки рендеринга*

⇒ *пояснение**:

[Отвечают за финальную стадию рендеринга, когда пиксельные данные выводятся на дисплей. Они выполняют такие операции, как сглаживание и тестирование глубины. Количество блоков рендеринга может влиять на способность GPU быстро обрабатывать изображения высокого разрешения.]

- *Блоки отображения текстур*

⇒ *пояснение**:

[Выполняют операции с текстурами во время рендеринга графики. Текстуры — это изображения, которые накладывают на 3D-модели для придания им реалистичного вида. Блоки отображения текстур отвечают фильтрацию и отображение.]

⇒ }
*Виды**:

- { • *Интегрированные*

⇒ *пояснение**:

[Встроены в тот же чип, что и центральный процессор (CPU). Они делят ресурсы памяти с CPU, что приводит к высокоэффективному энергопотреблению.]

- *Дискретные*

⇒ *пояснение**:

[Такие процессоры создают с учетом требований производительности, поэтому они обладают большой вычислительной мощностью.]

}

Тензорный процессор

:= [TPU]

:= [матричный процессор, специализированный для работы с нейросетями.]

⊂ *Нейронный процессор*

⇒ *Основные особенности**:

- { • *Быстрая обработка большого количества математических операций*
- *меньший физический объем*
- *радикальное устранение узкого места архитектуры фон- Неймана*
- *уменьшение потребления энергии*

}

⇒ *Основные составляющие**:

- { • *Систолический массив*
:= [Используется для умножения матриц.]
- *Логика*
:=

[Используется для управления всеми элементами.]

- *Буфер данных*

}
⇒ *Команды**:

- {• *ReadHostMemory*
:= [Чтение данных переданных от хоста и запись в буфер.]
- *ReadWeights*
:= [Загрузка матрицы весов из памяти весов.]
- *MatrixMultiply/Convolve*
:= [Выполнение матричного умножения или свертки в буфере с загруженными весами.]
- *Activate*
:= [Вычисление нелинейной функции над результатом матричного умножения.]
- *WriteHostMemory*
:= [Запись из буфера в память хоста.]

}

Программно-аппаратная архитектура параллельных вычислений

:= [CUDA]
⇒ *Этапы запуска**:

- {• *Выделение памяти хостом*
- *Копирование данных в память устройства*
- *Запуск ядра*
- *Исполнение ядра*
- *Копирование данных в память хоста*

}
⇒ *Преимущества**:

- {• *Простота понимания архитектуры*
⇒ *пояснение**:
[Интерфейс программирования приложений CUDA основан на стандартном языке программирования Си с некоторыми ограничениями.]
- *Эффективность*
⇒ *пояснение**:
[Более эффективные транзакции между памятью центрального процессора и видеопамятью.]
- *Доступность*
⇒ *пояснение**:
[Поддержка компиляции кода GPU средствами открытого проекта LLVM.]
- *Скорость*
⇒ *пояснение**:
[Архитектура увеличивает скорость расчета текстур и сложных графических объектов, что полезно при работе с интеллектуальными системами.]

}

Нейронный процессор

:= [NPU]

:= [специализированный класс микропроцессоров и сопроцессоров, используемый для аппаратного ускорения работы алгоритмов искусственных нейронных сетей, компьютерного зрения, распознавания по голосу, машинного обучения и других методов искусственного интеллекта.]

:= [ИИ-ускоритель]

⇒ *Примеры*:*

- {• *Нейроморфные процессоры*
- *Тензорные процессоры*
- *Процессоры машинного зрения*

}

⇒ *Компоненты*:*

- {• *Регистры*
- := [Устройство для записи, хранения и считывания n-разрядных двоичных данных и выполнения других операций над ними.]
- *Блоки памяти магазинного типа*
- *Коммутатор*
- *Вычислительное устройство*

}

⇒ *Область применения*:*

- {• *Управление беспилотным автомобилем*
- *Диагностика в здравоохранении*
- *Машинный перевод*
- *Поисковая система*

}

3 ФОРМАЛЬНАЯ СЕМАНТИЧЕСКАЯ СПЕЦИФИКАЦИЯ БИБЛИОГРАФИЧЕСКИХ ИСТОЧНИКОВ

*Анализ тензорных процессоров на предмет эффективности применения для
расчета систологических массивов нейронных сетей*

⇒ *автор**:

- Стрелец А. И.
- Протопопова Ю. Д.
- Тоичкин Д. В.
- Ключникова Б. В.

⇒ *ключевой знак**:

- Тензорный процессор
- Буфер данных
- Систолический массив
- Команды тензорного процессора

⇒ *тип источника**:

[статья]

⇒ *аннотация**:

[В работе анализируется использование тензорных процессоров для параллельных вычислений нейросвязей в сети.]

⇒ *цитата**:

[Тензорный процессор представляет собой систолический массив для выполнения умножения матриц, буфер данных, логику для управления этими элементами.]

⇒ *пояснение**:

[Тензорный процессор]

⇒ *цитата**:

[Процессор обладает полным набором из 5 основных команд. ReadHostMemory — чтение данных, переданных от хоста и запись в унифицированный буфер. ReadWeights — загрузить матрицу весов из памяти весов (WeightFIFO) в модуль матричного умножения. Веса — это синоним второго операнда в матричном умножении, который появляется в алгоритмах машинного обучения. MatrixMultiply/Convolve — выполнить матричное умножение или свертку над данными в унифицированном буфере и уже загруженными весами. Activate — вычислить нелинейную функцию над результатом матричного умножения. WriteHostMemory — выполнить запись из буфера в память хоста.]

⇒ *пояснение**:

[Команды тензорного процессора]

⇒ *цитата**:

[Tensor Processing Unit является проявлением важной тенденции в вычислительной технике: когда рост производительности центральных процессоров за счет увеличения числа транзисторов сильно замедляется, приходится изыскивать пути ускорения вычислений путем разработки специализированных устройств под конкретные задачи. Одной из таких задач является вычисления для нейронных сетей. Выигрыш здесь состоит в том, что в этих алгоритмах используется очень ограниченный набор операций, а технология применима к огромному числу сфер человеческой деятельности.]

⇒ *принцип**:

[Тензорный процессор]
 ⇐ сравнение*:
 { • Центральный процессор
 • Тензорный процессор
 }

Все, что нужно знать про GPU: история технологии, архитектура графических процессоров и сферы их применения

⇒ ключевой знак*:

- Графический процессор
- Вычислительные блоки
- Ядра процессора
- Интегрированный графический процессор
- Дискретный графический процессор

⇒ тип источника*:

[статья]

⇒ цитата*:

[GPU — графический процессор, который предназначен для ускорения рендеринга графики и параллельных вычислений.]

⇒ пояснение*:

[Графический процессор]

⇒ цитата*:

[Роль GPU выходит за рамки рендеринга графики. С появлением вычислений общего назначения на графических процессорах (GPGPU) эти процессоры нашли применение в областях, где требуются высокопроизводительные вычисления. Например, ускорение задач искусственного интеллекта (ИИ), глубокое обучение для высокоскоростной аналитики данных и научных симуляций.]

⇒ принцип*:

[Графический процессор]

⇒ цитата*:

[Вычислительные блоки образуют основные вычислительные элементы в GPU.]

⇒ принцип*:

[Вычислительные блоки]

⇒ цитата*:

[Есть два вида GPU: интегрированные и специализированные. У каждого вида есть свои характеристики, возможности и сценарии использования. Интегрированные GPU встроены в тот же чип, что и центральный процессор (CPU). В специализированных GPU автономные компоненты оснащены собственной выделенной памятью.]

⇐ сравнение*:

- { • Интегрированный графический процессор
- Дискретный графический процессор
- }

ЗАКЛЮЧЕНИЕ

Проведена работа по формализации основных понятий связанных с современным аппаратным обеспечением в области интеллектуальных систем, таких как электронно-вычислительная машина, машина фон-Неймана, графический процессор, тензорный процессор и другие. При формализации данных понятий информация была взята из различных библиографических источников, формализация, которых также приведена в отчете. Современные массовые разработки в сфере искусственного интеллекта, например создание нейронных сетей, нуждаются в очень высокой производительности аппаратного обеспечения. Специализированные разработки процессоров для создания интеллектуальных систем важны при создании любого вида интеллектуальной системы, так как они снижают затраты энергии, времени и других ресурсов на обучение и запуск системы.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] ITGLOBAL,. История технологии архитектура графических процессоров / ITGLOBAL // HABR.com. — 2023.
- [2] Servernews,. Нейронный процессор / Servernews // Wikipedia.org. — 2024.
- [3] А., Умнова. Определение и принцип работы ЭВМ / Умнова А. // Skyeng. — 2024.
- [4] Анализ тензорных процессоров на предмет эффективности применения для расчета систологических массивов нейронных сетей / А. И. Стрелец [et al.] // Форум молодых ученых 2018. — 2018.
- [5] Боресков, А. В. Cuda / А. В. Боресков, В. Фролов, И. Осколков // Wikipedia.org. — 2024.
- [6] Федотова, Е. Л. Электронная вычислительная машина / Е. Л. Федотова, А. А. Федотов // Wikipedia.org. — 2024.